

Systeme de Recommandation de Parcours d'Etudes

Raisonnement hybride : Moteur symbolique + Analyse contextuelle
Gestion explicite de l'incertitude

Groupe 5 - Raisonnement IA

FANOMEZANTSOA Maminiaina Sitraka
Membres du groupe

Promotion 2025-2026 | EMIT Fianarantsoa | Departement SDIA

1. Introduction

Ce projet developpe un systeme intelligent de recommandation de parcours d'etudes universitaires. Face a la pluralite des formations disponibles et la diversite des profils etudiants, l'objectif est de proposer automatiquement les formations les plus adaptees en fonction des competences, interets et contraintes de chaque etudiant.

1.1 Definition du probleme

Entree : Profil etudiant (competences, niveau d'etudes, interets, contraintes budget/duree/localisation).

Base de connaissances : 12 formations couvrant informatique, data science, droit, marketing, design, biologie, psychologie, gestion. Chaque formation a des prerequis, un cout, une duree, une localisation et un taux de satisfaction.

Objectif : Produire une liste ordonnee de formations recommandees avec un score de confiance et une justification.

Cout des erreurs : Une mauvaise recommandation peut induire l'etudiant dans l'erreur, lui faire perdre du temps et de l'argent. Le systeme doit donc etre transparent sur son degre de certitude.

1.2 Exigences du projet

- Au moins 2 approches complementaires (logique/regles + LLM)
- Traitement explicite de l'incertitude, incompletude et contradictions
- 10 cas de test minimum dont 3 cas limites
- Projet reproductible (donnees, code, commande de lancement)

2. Approches complementaires

2.1 Moteur symbolique (Regles formelles)

Le moteur de regles implemente un systeme de recommandation en deux phases :

- Phase 1 - Filtrage dur : Verification des prerequis obligatoires, budget maximum, duree maximale. Les formations non-eligibles sont eliminees.
- Phase 2 - Scoring : Pour chaque formation eligible, calcul d'un score base sur 7 criteres ponderees : correspondance domaine-interets (25%), qualite prerequis (30%), pertinence competences (15%), fit budget (10%), fit duree (10%), localisation (5%), satisfaction (5%).
- Facteur d'alignement domaine : Un multiplicateur penalise les formations dont le domaine n'a aucun lien avec les competences ou interets de l'etudiant (facteur 0.15).

```
score_final = min(100, score_pref x alignement_domaine x 100)
alignement = 1.0 si domaine/interet correspond
alignement = 0.15 si aucun lien detecte
```

2.2 Analyse contextuelle (LLM / Fallback)

Le deuxieme moteur utilise un RAG (Retrieval-Augmented Generation) structure :

- Pre-filtrage : Selection des formations candidates selon les contraintes dures.
- Prompt structure : Le contexte etudiant (profil + formations candidates) est injecte dans un prompt JSON contraint avec schema de sortie garanti.
- Sortie interpretable : Chaque recommandation comprend un score (0-1), une confiance (0-1) et une justification textuelle.
- Mode fallback : En absence de LLM externe, un moteur deterministe reproduit le meme format de sortie avec des regles heuristiques.

3. Integration hybride et incertitude

3.1 Moteur hybride

Le moteur hybride fusionne les sorties des deux moteurs avec une formule ponderee :

```
score_hybride = alpha x score_regles + beta x score_llm  
alpha = beta = 0.5 (equilibre)
```

Le systeme detecte les desaccords entre les moteurs : quand les deux engines classent differemment les 2 formations top, un avertissement est affiche a l'utilisateur.

3.2 Analyse d'incertitude

Le module d'incertitude evalue la qualite du profil etudiant avant de recommander :

- Completude : Pourcentage du profil rempli (competences declarees / 9 domaines possibles).
- Informations manquantes : Detection des donnees absentes (pas de competences, pas d'interets, pas de budget).
- Contradictions : Ex : budget a 0 EUR avec des formations couteuses ; interets incoherents avec le niveau d'etudes.
- Avertissements : Profil tres incomplet, donnees potentiellement fausses.

L'analyse d'incertitude est affichee avant les recommandations pour informer l'utilisateur du degre de fiabilite du resultat.

4. Resultats et validation

4.1 Cas de test

10 profils etudiants ont ete testes, dont 3 cas limites :

- S04 - Profil vide : Aucune competence, aucun interet. S05 - Profil contradictoire : Budget 0 mais interets couteux. S06 - Budget 0 EUR : Aucune formation eligible.
- S01 a S03 - Profils standards : Verification que les formations pertinentes arrivent en tete.
- S07 a S10 - Profils varies : Differentes combinaisons domaine/niveau/budget.

50 tests automatises valident le systeme (pytest) en moins d'une seconde.

4.2 Exemple concret : Alice Martin

Alice Martin (bac+3, competences informatique et maths, interets IA/ML) :

- #1 Master Intelligence Artificielle : score 72/100, confiance 91%
- #2 Formation Developpeur Web Full Stack : score 51/100, confiance 41%
- #9 Licence de Droit : score 7/100 (penalise par manque de lien avec ses competences)

4.3 Import de CV

Le systeme accepte l'import d'un CV au format PDF. Le parser extrait automatiquement le nom, le niveau d'etudes, les technologies maatriseees (22 technologies detectees sur le CV test) et les interets. Le profil extrait est utilise directement pour la recommandation.

5. Architecture technique

Structure du projet :

```
study-path-recommender/  
  src/models/      student.py, program.py  
  src/engines/     rule_engine.py, llm_engine.py, hybrid.py  
  src/utils/       uncertainty.py, cv_parser.py  
  src/knowledge/   loader.py, programs_catalog.json  
  config/         rules.json, .env  
  data/           sample_students.json  
  tests/          50 tests (rule_engine, hybrid, uncertainty, comparison)  
  app.py          Interface Streamlit (3 onglets)
```

5.2 Technologies

- Python 3.12 | Pydantic (modeles de donnees) | Streamlit (UI)
- pdfplumber (extraction PDF) | pytest (tests) | python-dotenv (config)

6. Conclusion

Ce projet demontre qu'un systeme de recommandation de formations peut etre construit avec deux approches complementaires : un moteur symbolique base sur des regles formelles et un moteur d'analyse contextuelle. La gestion de l'incertitude (completude, contradictions) et l'import de CV renforcent l'utilite pratique du systeme. Le moteur hybride avec detection de desaccords fournit des recommandations robustes et transparentes.

Extensions possibles : Integration d'un vrai LLM (Ollama/OpenAI), ajout d'un reseau bayesien pour modeliser les probabilites de reussite, extension du catalogue a 50+ formations.